МИНОБРНАУКИ РОССИИ САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА) Кафедра МО ЭВМ

ОТЧЕТ

по лабораторной работе №5 по дисциплине «Построение и анализ алгоритмов»

Тема: Ахо-Корасик

Студентка гр. 9383	 Чебесова И. Д
Преподаватель	 Фирсов М. А.

Санкт-Петербург 2021

Цель работы.

Познакомиться с алгоритмом Ахо-Корасик, реализовать алгоритм на одном из языков программирования.

Вариант 0. Работа без варианта. Решение двух задач на платформе степик.

Задание.

Задание 1.

Разработайте программу, решающую задачу точного поиска набора образцов.

Вход:

Первая строка содержит текст (T, $1 \le |T| \le 100000$).

Вторая - число n (1 \leq n \leq 3000), каждая следующая из n строк содержит шаблон из набора P={p_1,...p_n} 1 \leq |p_i| \leq 75

Все строки содержат символы из алфавита {A,C,G,T,N}

Выход:

Все вхождения образцов из Р в Т.

Каждое вхождение образца в текст представить в виде двух чисел - і р

Где i - позиция в тексте (нумерация начинается с 1), с которой начинается вхождение образца с номером р (нумерация образцов начинается с 1).

Строки выхода должны быть отсортированы по возрастанию, сначала номера позиции, затем номера шаблона.

Sample Input:

NTAG

3

TAGT

TAG

Т

Sample Output:

2 2

23

Задание 2.

Используя реализацию точного множественного поиска, решите задачу точного поиска для одного образца с джокером.

В шаблоне встречается специальный символ, именуемый джокером (wild card), который "совпадает" с любым символом. По заданному содержащему шаблоны образцу Р необходимо найти все вхождения Р в текст Т.

Например, образец ab??c?ab??c? с джокером ?? встречается дважды в тексте хаbvccbababcaxxabvccbababcax.

Символ джокер не входит в алфавит, символы которого используются в Т. Каждый джокер соответствует одному символу, а не подстроке неопределённой длины. В шаблон входит хотя бы один символ не джокер, т.е. шаблоны вида ??? недопустимы.

Все строки содержат символы из алфавита {A,C,G,T,N}

Вход:

Текст (T, $1 \le |T| \le 100000$)

Шаблон (P, $1 \le |P| \le 40$)

Символ джокера

Выход:

Строки с номерами позиций вхождений шаблона (каждая строка содержит только один номер).

Номера должны выводиться в порядке возрастания.

Sample Input:

ACTANCA

A\$\$A\$

\$

Sample Output:

1

Основные теоретические положения.

Чтобы говорить об алгоритме необходимо ввести ряд понятий:

Бор — структура данных для хранения набора строк, представляющая из себя подвешенное дерево с символами на рёбрах. Строки получаются последовательной записью всех символов, хранящихся на рёбрах между корнем бора и терминальной вершиной. Размер бора линейно зависит от суммы длин всех строк, а поиск в бору занимает время, пропорциональное длине образца.

Бор для набора образцов {he,she,his,hers}:

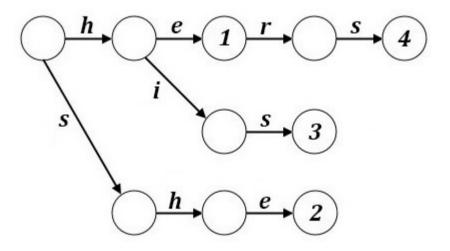


Рисунок 1 – пример бора для набора образцов

Корень обозначается пустым символом (в моей реализации — это специальный символ, который не входит в алфавит - @).

Видно, что некоторые вершины имеют число — это обозначает, что вершина является *терминальной* (конечной) для определенного образца.

Назовем суффиксной ссылкой вершины v указатель на вершину u, такую что строка u — наибольший собственный суффикс строки v, или, если

такой вершины нет в боре, то указатель на корень. В частности, ссылка из корня ведет в него же.

Например, для бора:

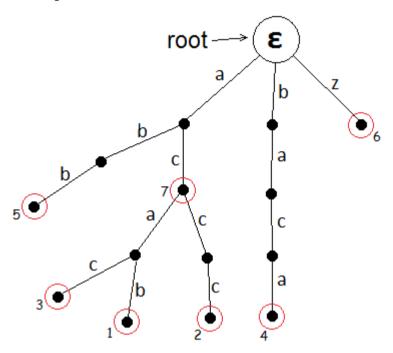


Рисунок 2 – пример бора

Суффиксные ссылки будут выглядеть следующим образом:

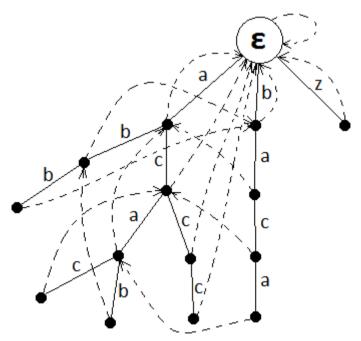


Рисунок 3 – пример суффиксных ссылок в боре

Наша задача — построить *конечный детерминированный автомат*. Состояние автомата — это какая-то вершина бора. Переход из состояний

осуществляется по двум параметрам — текущей вершине v и символу ch. по которому нам надо сдвинуться из этой вершины. Необходимо найти вершину u, которая обозначает наидлиннейшую строку, состоящую из суффикса строки v (возможно нулевого) + символа ch. Если такого в боре нет, то идем в корень.

Описание алгоритма.

Алгоритм состоит из трех этапов: построение бора, добавление суффиксных ссылок и самого прохода с помощью автомата.

1. Построение бора.

Бор строится из подстрок, переданных для поиска. Рассматривая каждый образец последовательно добавляем вершины в бор.

- если по текущему символу подстроки можно перейти в следующую вершину – переходим
- если ребра с текущим символом нет создаем ребро, добавляя вершину и переходим в нее
- 2. Преобразование бора, добавлением суффиксных ссылок для каждой вершины.

При построении следует помнить:

- ссылка из корня идет в корень
- ссылка из потомка корня идет в корень
- ссылка из любой другой вершины с ребром е ищется следующим образом:
 - смотрим на родителя
 - пытаемся пройти по ребру е
 - если не получается поднимаемся выше и повторяем
- если уперлись в корень и так и не нашли ребро что ж, ссылка пойдет в корень

 иначе запоминаем ссылку на ту вершину, в которую попали, переходя по ребрам

Также еще одним этапом является построение конечной ссылки. Для этого:

- ходим по ссылкам, пока не упремся в терминальную конечную вершину
 - нашли отлично, запоминаем
 - не нашли и уперлись в корень что ж, ссылка пуста
 - 3. Сам алгоритм.
- пытаемся перейти в автомате по ребру с текущим рассматриваемым символом
 - если такое ребро есть переходим
- если такого ребра нет переходим по суффиксной ссылке (если были в корне, то перейдем в него же) и повторяем с первой точки
- если попали в терминальную вершину то ура, нашли вхождение запоминаем
 - проходим цепочку конечных ссылок, запоминая результаты

Для решения задания с джокером используется тот же алгоритм с некоторыми изменениями:

- выделяем максимальные подстроки, не содержащие джокера из заданного шаблона
 - для каждого такого образца запоминаем смещение
- внутри алгоритма создаем дополнительный массив, заполненный 0, длинна которого равна длине текста
 - запускаем поиск по тексту
- если нашли подстроку, то увеличиваем на 1 значение ячейки, которое соответствует разности между номером начального символа образца в тексте и смещением образца (если их несколько то проделать со всеми)

Таким образом получится, что шаблонная подстрока будет начинаться в тех местах текста, для которых соответствующая ячейка массива содержит количество образцов с учетом кратности.

Сложность алгоритма Axo-Корасика: O(M*k+N+t), где M – размер бора, k – размер алфавита, t - количество всех возможных вхождений всех строк-образцов, а N – длина исходной строки.

Описание функций и структур данных.

struct Bor – для хранения бора и работы с ним.

Его поля:

char edge; - хранит ребро для перехода в следующую вершину (вес ребра – символ char)

int final_vertex_number; - хранит номер образца соответствующий
конечной (терминальной вершине)

std::vector < Bor*> children; - хранит ссылки на детей вершины

Bor* parent; - хранит ссылку на родителя

Bor* suffix_link; - хранит суффиксную ссылку

Bor* end_suffix_link; - хранит конечную ссылку

Методы:

Bor* go_to_child_by_edge (char child_edge) – для перехода в потопка по заданному ребру

void add_suffix_link () – для добавления суффиксной ссылки в вершину

 $struct\ DFA$ — структура, которая предоставляет возможность работать с автоматом и содержит сам алгоритм.

Поля:

Bor* root; - для хранения корня

std::vector<std::string> patterns; - для хранения массива шаблонов

Методы:

void bild_bor (std::vector<std::string>& new_patterns) – функция для
построения бора по переданному массиву шаблонов

void add_all_suffix_links () – для добавления всех суффиксных ссылок
void aho_corasick (std::string& text) - сам алгоритм

void print_result (std::vector<std::pair<int, int>>& result) – для печати
peзультата на экран

Дополнительные функции:

bool cmp_for_vec_pair(std::pair<int, int> elem1, std::pair<int, int> elem2)
– для сортировки вектора пар по возрастанию обоих параметров

Тестирование.

Задание 1.

Входные данные:

NTAG

3

TAGT

TAG

Τ

Выходные данные:

Рисунок 4 – тестирование программы 1

Входные данные:

ABCDEF

5

A

В

CD

CDEF

DC

Выходные данные:

Рисунок 5 – тестирование программы 2

Задание 2.

Входные данные:

ACTANCA

A\$\$A\$

\$

Выходные данные:

Введите текст Т:

Введите шаблон:

Введите символ джокера:

Результат работы алгоритма:

1

Входные данные:

ACTANCAACTAN

A\$\$A\$

\$

Выходные данные:

Введите текст Т:

Введите шаблон:

Введите символ джокера:

Результат работы алгоритма:

1

4

8

Выводы.

В ходе выполнения лабораторной работы был изучен и реализован алгоритм Ахо-Корасик, который находит все вхождения подстрок шаблонов в заданный текст. Также был реализован поиск подстроки с джокером с использованием данного алгоритма.

ПРИЛОЖЕНИЕ А

ИСХОДНЫЙ КОД ПРОГРАММЫ

Файл task1.cpp:

```
#include <iostream>
      #include <string>
      #include <vector>
      #include <queue>
      #include <algorithm>
      //компаратор для сортировки контейнера std::vector<std::pair<int, int>>
по возрастанию обоих элементов пары
      bool cmp_for_vec_pair(std::pair<int, int> elem1, std::pair<int, int>
elem2)
      {
          if (elem1.first < elem2.first)</pre>
          {
              return true;
          }
          else if (elem1.first == elem2.first && elem1.second < elem2.second)</pre>
              return true;
          }
          else
          {
              return false;
          }
      }
      //структура для хранени и работы с бором, в частности для добавления
суффиксной ссылки для текущей вершины
      struct Bor
      {
          char edge;
          int final_vertex_number;
          std::vector<Bor*> children;
```

```
Bor* suffix_link;
          Bor* end_suffix_link;
          Bor (char new_edge, Bor* new_parent)
          {
              edge = new_edge;
              final_vertex_number = 0;
              parent = new_parent;
              suffix_link = nullptr;
              end_suffix_link = nullptr;
          }
          //функция для спуска по бору по ребру к потомку
          Bor* go_to_child_by_edge (char child_edge)
          {
              for (auto &child : children)
              {
                  if (child->edge == child_edge)
                  {
                      return child;
                  }
              }
              return nullptr;
          }
          //функция создания ссылки для одной вершины
          void add_suffix_link ()
          {
              if (edge == '@') //если это корень, то ссылка в себя
              {
                  std::cout << "Текущая вершина - корень, ссылается на себя.\
n";
                  suffix_link = this;
              }
              else if (parent->edge == '@') //если предок корень, то ссылка в
предка, т.е. в корень
                                       15
```

Bor* parent;

```
{
                  std::cout << "Текущая вершина с ребром " << edge << "
потомок корня, ссылается на корень.\n";
                  suffix_link = parent;
              }
              else //если же корень не близко - нужно смотреть
                  std::cout << "Текущая вершина с ребром " << edge << " далека
от корня, начато построение ссылки. ";
                  Bor* current_state = parent->suffix_link; //суффиксная
ссылка родителя
                  Bor* next_state = current_state-
>go_to_child_by_edge(edge); //пытаемся от родителя пройти по текущему символу
                  while (next_state == nullptr) //если пройти не получилось -
нет такого ребра
                  {
                      if (current_state->edge == '@') //если уперлись в корень
                      {
                          next_state = current_state; //то сохраняем для
ссылки корень и выходим
                          break;
                          //если нет
                      }
                      current_state = current_state->suffix_link; //проходим
по ссылке дальше
                      next_state = current_state-
>go_to_child_by_edge(edge); //пытаемся снова спуститься
                  suffix_link = next_state; //сохраняем нашу получившуюся
ссылку
                  //далее проверим вершину на конечность
                  while (next_state->final_vertex_number == 0) //если вершина
не конечная для какой-то подстроки
                  {
                      if (next_state->edge == '@') //если пришли в корень, то
дальше некуда, заканчиваем
                      {
                          break;
                      }
                      next_state = next_state->suffix_link; //иначе идем по
суффиксной ссылке дальше
```

```
}
                 if (next_state->final_vertex_number > 0) //если так
получилось, что мы нашли вершину и она конечная
                 {
                     end_suffix_link = next_state; //запоминаем ее в конечную
суффиксную ссылку
                 }
                 std::cout << "Построение ссылки завершено.\n";
             }
         }
     };
     //структура для конечного детерминированного автомата
     struct DFA
     {
         Bor* root;
         std::vector<std::string> patterns;
         DFA (std::vector<std::string>& new_patterns)
         {
             root = new Bor('@', nullptr);
             patterns = new_patterns;
             bild_bor(new_patterns);
             add_all_suffix_links();
         }
         //создание бора путем добавления в него строк-паттернов
         void bild_bor (std::vector<std::string>& new_patterns)
         {
             std::cout << "-----\n";
             int string_number = 1;
             for (auto &current_pattern : new_patterns)
             {
                 Bor* current_state = root; //текущее состояние в корне
                 for (int i = 0; i < current_pattern.size(); i++)</pre>
                 {
```

```
Bor* next_state = current_state-
>go_to_child_by_edge(current_pattern[i]); //пробуем перейти к ребенку
                     if (next_state == nullptr) //если вершины при переходе
по ребру еще нет
                     {
                         next_state = new Bor(current_pattern[i],
current_state); //создаем вершину
                         current_state-
>children.push_back(next_state); //добавляем ее в число детей
                     }
                     if (i == current_pattern.size()-1) //если строка
закончилась - то текущая вершина терминальная для данной подстроки
                         next_state->final_vertex_number =
string_number; //добавляем ее номер
                         std::cout << "Строка " << current_pattern << "
добавлена в бор\п";
                     }
                     else
                     {
                         current_state = next_state; //иначе просто переходим
дальше, т.к. вершина уже есть
                     }
                 }
                 string_number++;
             }
             std::cout << "-----\n\
n";
         }
         //создаем суффиксные ссылки для каждой вершины
         void add_all_suffix_links ()
         {
             std::cout << "------Начинаем создание суффиксных
ссылок----\n";
             std::queue<Bor*> queue; //используем очередь, чтобы ходить по
вершинам
             Bor* current_state = root; //начинаем с корня
             queue.push(root);
             while (!queue.empty()) //пока есть по чему ходить
             {
```

```
current_state->add_suffix_link(); //создаем ссылку для
текущей вершины
                 queue.pop(); //удаляем ее из очереди, т.к. обработали
                 for (auto &current_child : current_state-
>children) //добавляем всех ее детей в очередь на обработку
                 {
                     queue.push(current_child);
                 }
                 current_state = queue.front(); //переходим к следующей в
очереди вершине для обработки
             }
             std::cout << "-----Создание суффиксных ссылок
закончено-----\n\n";
         }
         //сам алгоритм Ахо-Корасик
         void aho_corasick (std::string& text)
         {
             std::cout << "------Начинаем алгоритм Ахо-
Корасика----\n";
             Bor* current_state = root; //начинаем хождение из корня
             std::vector<std::pair<int, int>> result; //вектор записи
результата
             for (int i = 0; i < text.size(); i++) //проходимся по символам
текста
             {
                 Bor* next_state = current_state-
>go_to_child_by_edge(text[i]); //спускаемся из текущей вершине по ребру из
текста к потомку
                 while (next_state == nullptr) //если такого ребра у нас нет
                 {
                     if (current_state == root) //если мы сейчас находимся в
корне переходим в него же и прерываем
                     {
                         next_state = current_state;
                         break;
                     }
                     current_state = current_state->suffix_link; //если нет,
то переходим по суффиксной ссылке
                     next_state = current_state-
>go_to_child_by_edge(text[i]); //и снова пытаемся спустится
```

```
}
                 if (next_state->final_vertex_number > 0) //если мы достигли
конечной вершины какого-то слова-запоминаем
                 {
                     std::cout << "Найдено вхождение образца: " <<
patterns[next_state->final_vertex_number-1] << '\n';</pre>
                     result.emplace_back(i-patterns[next_state-
>final_vertex_number-1].size()+2, next_state->final_vertex_number);
                 }
                 if (next_state->end_suffix_link != nullptr) //если для
следующего состояния есть ссылка на конец
                 {
                     Bor* tmp_state = next_state->end_suffix_link;
                     while (tmp_state != nullptr) //то пока она указывает на
конец - добавляем в результат
                     {
                         result.emplace_back(i-patterns[tmp_state-
>final_vertex_number-1].size()+2, tmp_state->final_vertex_number);
                         tmp_state = tmp_state->end_suffix_link;
                     }
                 }
                 current_state = next_state; //переходим к следующей
             }
             std::cout << "-----Алгоритм Ахо-Корасика
закончен-----\n\n";
             std::sort(result.begin(), result.end(),
cmp_for_vec_pair); //сортируем согласно заданию
             print_result(result); //печатаем на экран
         }
         //функция печати на экран результата
         void print_result (std::vector<std::pair<int, int>>& result)
         {
             std::cout << "-----\n";
             for (auto &answer : result)
             {
             std::cout << "Позиция в тексте: " << answer.first << " Номер
образца: " << answer.second << '\n';
         }
```

```
int main ()
      {
          std::cout << "Введите текст Т:\n";
          std::string text;
          std::cin >> text;
          std::cout << "Введите количество подстрок:\n";
          int number_pattenrs;
          std::cin >> number_pattenrs;
          std::cout << "Введите все подстроки:\n\n";
          std::vector<std::string> patterns;
          std::string new_pattern;
          for (int i = 0; i < number_pattenrs; i++)</pre>
          {
              std::cin >> new_pattern;
              patterns.push_back(new_pattern);
          }
          DFA new_DFA(patterns);
          new_DFA.aho_corasick(text);
          return 0;
      }
      Файл task2.cpp:
      #include <iostream>
      #include <string>
      #include <vector>
      #include <queue>
      #include <algorithm>
      bool cmp_for_vec_pair(std::pair<int, int> elem1, std::pair<int, int>
elem2)
      {
          if (elem1.first < elem2.first)</pre>
          {
              return true;
```

};

```
}
    else if (elem1.first == elem2.first && elem1.second < elem2.second)</pre>
    {
        return true;
    }
    else
    {
        return false;
    }
}
struct Bor
{
    char edge;
    std::vector<int> final_vertex_number;
    std::vector<Bor*> children;
    Bor* parent;
    Bor* suffix_link;
    Bor* end_suffix_link;
    Bor (char new_edge, Bor* new_parent)
    {
        edge = new_edge;
        parent = new_parent;
        suffix_link = nullptr;
        end_suffix_link = nullptr;
    }
    Bor* go_to_child_by_edge (char child_edge)
    {
        for (auto &child : children)
        {
            if (child->edge == child_edge)
            {
                return child;
            }
```

```
}
    return nullptr;
}
void add_suffix_link ()
{
    if (edge == '@')
    {
        suffix_link = this;
    }
    else if (parent->edge == '@')
    {
        suffix_link = parent;
    }
    else
    {
        Bor* current_state = parent->suffix_link;
        Bor* next_state = current_state->go_to_child_by_edge(edge);
        while (next_state == nullptr)
        {
            if (current_state->edge == '@')
            {
                next_state = current_state;
                break;
            }
            current_state = current_state->suffix_link;
            next_state = current_state->go_to_child_by_edge(edge);
        }
        suffix_link = next_state;
        Bor* tmp_state = next_state;
        while (tmp_state->final_vertex_number.empty())
        {
            if (tmp_state->edge == '@')
            {
                break;
            }
```

```
tmp_state = tmp_state->suffix_link;
                  }
                  if (!tmp_state->final_vertex_number.empty())
                  {
                      end_suffix_link = tmp_state;
                  }
              }
          }
      };
      struct DFA
      {
          Bor* root;
          std::vector<std::pair<std::string, int>> patterns;
          int last_jokers;
          DFA (std::vector<std::pair<std::string, int>>& new_patterns, int
new_last_jokers)
          {
              root = new Bor('@', nullptr);
              last_jokers = new_last_jokers;
              patterns = new_patterns;
              add_patterns(new_patterns);
              add_all_suffix_links();
          }
          void add_patterns (std::vector<std::pair<std::string, int>>&
new_patterns)
          {
              for (auto &current_pattern : new_patterns)
              {
                  Bor* current_state = root;
                  for (int i = 0; i < current_pattern.first.size(); i++)</pre>
                      Bor* next_state = current_state-
>go_to_child_by_edge(current_pattern.first[i]);
                      if (next_state == nullptr)
```

```
{
                          next_state = new Bor(current_pattern.first[i],
current_state);
                          current_state->children.push_back(next_state);
                      }
                      if (i == current_pattern.first.size()-1)
                      {
                          next_state-
>final_vertex_number.push_back(current_pattern.second);
                      }
                      else
                      {
                          current_state = next_state;
                      }
                  }
              }
          }
          void add_all_suffix_links ()
          {
              std::queue<Bor*> queue;
              Bor* current_state = root;
              queue.push(root);
              while (!queue.empty())
              {
                  current_state->add_suffix_link();
                  queue.pop();
                  for (auto &current_child : current_state->children)
                  {
                      queue.push(current_child);
                  }
                  current_state = queue.front();
              }
          }
          void aho_corasick (std::string& text)
          {
```

```
Bor* current_state = root;
              std::vector<int> length_patterns_current(text.size(), 0);
              for (int i = 0; i < text.size()-last_jokers; i++)</pre>
              {
                  Bor* next_state = current_state-
>go_to_child_by_edge(text[i]);
                  while (next_state == nullptr)
                  {
                      if (current_state == root)
                      {
                          next_state = current_state;
                          break;
                      }
                      current_state = current_state->suffix_link;
                      next_state = current_state-
>go_to_child_by_edge(text[i]);
                  }
                  for (auto &current_terminal : next_state-
>final_vertex_number)
                  {
                      if (i-current_terminal+1 >= 0)
                      {
                          length_patterns_current[i-current_terminal+1]++;
                      }
                  }
                  Bor* tmp_state = next_state->end_suffix_link;
                  while (tmp_state != nullptr)
                  {
                      for (auto &current_terminal : tmp_state-
>final_vertex_number)
                      {
                          if (i-current_terminal+1 >= 0)
                          {
                               length_patterns_current[i-current_terminal+1]++;
                          }
                      }
                      tmp_state = tmp_state->end_suffix_link;
                  }
```

```
current_state = next_state;
        }
        std::vector<int> result;
        for (int i = 0; i < length_patterns_current.size(); i++)</pre>
        {
            if (length_patterns_current[i] == patterns.size())
            {
                result.push_back(i+1);
            }
        }
        print_result(result);
    }
    void print_result(std::vector<int>& result)
    {
        std::cout << "Результат работы алгоритма: \n";
        sort(result.begin(), result.end());
        for (auto &answer : result)
        {
            std::cout << answer << '\n';
        }
    }
};
int main ()
{
    std::cout << "Введите текст Т:\n";
    std::string text;
    std::cin >> text;
    std::cout << "Введите шаблон:\n";
    std::string pattern;
    std::cin >> pattern;
    char joker;
    std::cout << "Введите символ джокера:\n";
    std::cin >> joker;
    std::vector<std::pair<std::string, int>> all_patterns;
```

```
std::string pattern_separation;
    int last_jokers;
    for (int i = 0; i < pattern.size(); i++)</pre>
    {
        if (pattern[i] != joker)
        {
            pattern_separation += pattern[i];
            last_jokers = 0;
        }
        else
        {
            if (!pattern_separation.empty())
            {
                all_patterns.emplace_back(pattern_separation, i);
            }
            pattern_separation = "";
            last_jokers++;
        }
    }
    if (!pattern_separation.empty())
    {
        all_patterns.emplace_back(pattern_separation, pattern.size());
    }
    DFA new_dfa(all_patterns, last_jokers);
    new_dfa.aho_corasick(text);
    return 0;
}
```